THE MATHEMATICS OF GENERALIZATION – CONTEXT

MATILDE, SEPTEMBER 2026

[on 18 Sep, I read some papers and start a project with chat on my thesis to immerse myself a little better into the context of my thesis. This file is the result.]

Generalization = a form of abstraction whereby common properties of specific instances are formulated as general concepts or claims. (Wikipedia)

Generalization [learning] = the process of appliyng a model to unseen data, that has been *learned* from some given data

Learning = extracting common features from some given data

Complexity = the effective size or richness of a class of predictors in terms of what they can learn given some data

Now, complexity is central to understanding generalization, because classical results in statistics find a monotonic relation between the complexity of the hypotheses class and the generalization power of the predictor (such a relationship is inverse). This is of course linked to the classical bias-variance tradeoff, where a too large complexity determines overfitting, but also to a classical result by Vapkin and Chervonenkis, who state that the richness of a class of events, measured by a *growth function*, controls the distance between the empirical and population probabilities of an event in the class (in the context of probability in general, not learning). This measure of complexity will then be referred to as VC dimension.

Also, when trying to understand what drives a good generalization ability, some hypotheses are formed, whose core component is a complexity measure [Jiang *Fantastic measures*]. Indeed, it can make sense to compare these complexity measures to compare such hypotheses. This further motivates why complexity is central to generalization.

So, a natural question is: how do we measure complexity?

In the finite case, the most straight-forward way is to count the number of models that an hypotheses class contains, i.e. the cardinality of the hypotheses set. This comes up in the bounds we propose. However, it always comes up due to trivial bounds, like union bounds or bounding the sup by the sum of the events. This leaves little intuition to why complexity should be a driver of generalization ability. $\star$

This problem, however, is distinct from (althoug related to) the problem of finding an informative bound that captures the structure of the learning problem. For what regards this problem, I will take as a reference the Boucheron et al. paper and study and implement these bounds:

(1) vanilla Hoeffding bound (done)

(2) variance-based bound

(3) noise inclusive bound

(4) localized Rademacher bound

This is the work for the next days: I will stop trying to understand their proofs, and instead I will directly write them in my setting and implement them.

Later on, I will possibly think of the $\star$ question, about complexity measures. Regarding this, I shall remember to read my conversation with Chat. Particularly useful. Some ideas that have arisen are to count only once

functions that behave similarly, i.e. have a similar deviation, or to compute the Rademacher complexity empirically instead of bounding it with Massart (which gives the same trivial bound as before).

Remember: **complexity si può pensare come il numero di funzioni nello spazio ma anche, più in generale, la capacità espressiva di quelle funzioni.** Per questo Rademacher ha senso, per questo si conta il numero di parametri.

Literature:

- Vapkin and Chervonenkis: classical paper studying the convergence of empirical frequency to population probability of that event. Sets the basis for class richness driving this convergence, it is not about learning, but this naturally translates to richness driving generalizatiom. Define measures that are predescendants of VC dimension.
- Jiang, Bengio, and others *Fantastic measures*: compare 40 complexity measures, both empirical and theoretical, on a large number of different models. Find that a mathematically correct measure is not always informative, and that sharpness measures seem to have the highest correlation with generalization. Link with bounds: some of these measures are taken from bounds.
- Boucheron et al.: la survey di diversi bound proposta da Loz. Sincera, mi sembra scritta malissimo anche rispetto a Jiang per esempio.

Setting

Io ho dei dati che vivono in $\mathcal{X}$ e sono distribuiti con una certa probabilità $p_{\mathcal{X}}$ con cui io campiono. Poi, genero

$$Y = f^*(X) + \sigma\varepsilon$$

dove f^* è la mia data-generating function, che posso scegliere, e $\varepsilon \sim \mathcal{N}(0, 1)$. Io poi voglio cercare di imparare f^* vedendo solo un dataset di taglia n di x e y. Cerco f^* in un insieme di ipotesi, $\mathcal{H}$. Quindi le cose con cui posso giocare sono p_X, la funzione generatrice f^*, la distribuzione di ε e la scelta di $\mathcal{H}$.

Ora, nell'influenzare come riesco ad imparare a predire le Y, f^*, la probabilità $p_{\mathcal{X}}$, e il mio set di ipotesi si parlano molto. Per esempio, se genero i dati con una funzione seno, ma poi la mia probabilità sulle X è concentrata in una zona in cui la derivata del seno non cambia segno, allora un insieme di ipotesi che guarda alle parabole sarà un buon insieme, perché quella funzione lì per quelle x si può approssimare bene con una parabola.

Quindi, siccome il nostro obiettivo è spiegare come impariamo, è probabile che la complessità della funzione generatrice (rappresentata e.g. dal numero di volte che questa cambia segno) e la distirbuzione sulle X giocheranno un ruolo.

Alcuni commenti:

· qui sopra uso X o x in modo poco preciso

· dai primi esperimenti sulla noise structure viene fuori che un noise Gaussiano e uno Bernoulliano non cambiano il risultato, anzi l'unica cosa imp è la porzione di input misclassificati a causa del noise (cioè che cambiano segno rispetto a quello di $f^*(x)$)

Recap al 1 ottobre

The situation until now is that we have an initial bound, $O(\sqrt{\log|\mathcal{H}|\ n})$, which does not capture the saturation of the test error. Then, we use another technic that is symmetrization and Rademacher complexity, and we observe that the Rademacher complexity bounds the gap, and that if we apply the Massart Lemma we obtain the same bound as above. Ora, la parte che non capisco:

- a luglio Loz mi aveva detto che il bound con la Rademacher non serve, e invece dovevo applicare il Massart Lemma

- allo stesso tempo però dice che quel bound saturava e che quindi quelle tecniche le potremmo riusare

> credo che il punto sia che dall'unione del bound con Rademacher e del Massart Lemma ottieni che boundi il gap con il minimo tra i due (mentre io consideravo il primo step solo come tool per ottenere il bound finale), e quindi ottieni un bound che satura.

btw, questo si motiva con il fatto che la Rademacher è sempre minore di 1.

Quindi, abbiamo un bound che satura, ma che non è sensibile nè al noise nè alla complessità della funzione sotto, perché infatti la Rademacher satura ad 1 per questioni strutturali sue di come è definita, non per questioni legate alla struttura del problema. Poi, proviamo a fare i bound del paper che includono la varianza e il noise. Anche questi non saturano, però sono sensibili a questi due fatti (devo ancora capire quello del noise come, e penso che questa noise condition sia usata spesso e quindi potrebbe essere interessante fare un bound che satura utilizzando questa $\star$).

Dunque, il nostro obiettivo sarebbe combinare le tecniche della rademacher e i bound sensibili a noise e complessità della funzione (quest'ultima non so come) per ottenere un bound che saturi e sia sensibile a questi fatti.

Una struttura secondo me sensata della tesi / presentazione:

questo è il setting

questo è il primo bound facile che vedi bene non include nulla della struttura del problema e non satura Rademacher in qualche modo $\rightarrow$ vedi che non si muove cambiando il rumore? (cioè fai dei plot con rumore diverso e fai vedere come cambia solo il test error empirico)

questi sono i bound con il noise la varianza ecc che non saturano

questo è quello che abbiamo provato a fare

Recap al 6 ottobre

allora noi abbiamo un primo bound che va banalmente come $O\left(\sqrt{d/n}\right)$ e si ottiene con la diseguaglianza di Hoeffding applicata alla variabile aleatoria che sto studiando (il gap tra l'errore vero e quello empirico), quindi solo un risultato di concentrazione di una qualsiasi variabile aleatoria, e poi si fa un bellissimo upper bound con la somma per tutte tutte le funzioni in H per poter trarre la conclusione per qualsiasi funzione in H, e quindi il mio stimatore. (e poi tail integration)

ripetiamo qui un attimo il ragionamento dello union bound: se un risultato di probabilità vale fissata una funzione f, vuol dire che ogni f ha un insieme di misura piccola I_f in cui quel risultato non vale. quello che sto facendo è: fissare una $f \rightarrow$ calcolare il valore di $Z(f)$ con dei dati $\rightarrow$ osservare che la probabilità (perché i dati sono aleatori) che i dati siano tali che $Z(f) > \varepsilon$ è è minore di un certo valore.

quando invece la f dipende dai dati, io prendo dei dati, quindi sono già soggetta all'aleatorietà, scelgo quindi una f_D, calcolo $Z(f_D)$ e voglio dire che anche la probabilità che $Z(f_D) > \varepsilon$ è piccola QUALSIASI SIANO I MIEI DATI

per dire questo, io voglio che anche l'unione $U_f(I_f)$ abbia misura piccola, perché questo vuol dire che posso fare uno statement sull'estimatore f_D in generale, prima di scegliere i dati, perché so che vale sempre.

ora, il ragionamento della localized Rademacher complexity è che a me non interessa che quel risultato holda per tutte le f per davvero, perché so che il mio estimatore cadrà in una certa zona di H qualsiasi siano i dati, cioè in un intorno di f^* (ovviamente assumendo un problema ben definito ecc ecc)

$\triangleright$ se io avessi un modo di misurare la caridnalità dell'insieme in cui di solito cade l'algoritmo potrei fare uno union bound sulle f lì dentro, e la cardinalità di questo insieme stabilizzerebbe una volta che ho solo leaf pure, quando non esploro più nuove soluzioni (saturation)

▷ cos'è che fa il teorema con la Rademacher complexity in relazione a questo? ho il dubbio che la parte della localizzazione sia distinta e ortogonale al motivo per cui la Rademacher complexity stabilizza. forse, il teorema con la Rademacher non migliora rispetto allo union bound (infatti su bounda il sup sempre con la somma su tutto H), ma usa una tecnica diversa rispetto alla Hoeffding inequality

Rademacher complexity

Si capisce meglio così.

Definition. The Rademacher complexity of a set of functions $f \in \mathcal{F}$ is

$$\mathcal{R}_n(\mathcal{F}) = \mathbb{E}_{x_1,\dots,x_n}\left[\mathbb{E}_{\xi_1,\dots,\xi_n}\left[\sup_{f\in\mathcal{F}} \frac{1}{n}\sum_i \xi_i f(x_i)\right]\right]$$

where $\frac{1}{n}\sum_i \xi_i f(x_i)$ is the correlation between ξ and $f(x)$. A high complexity means that for most values of ξ we can find a function f that is similar to the pattern. It is the highest when we can find a function f that correlates with any possible pattern.

In general, the following result holds

$$\mathbb{E}_{x_1,\dots,x_n}\left[\sup_{f\in\mathcal{F}} \frac{1}{n}\sum_i f(x_i) - \mathbb{E}_x[f(x)]\right] \leq 2\mathcal{R}_n(\mathcal{F})$$

where we look at the highest possible deviation of the empirical mean from the expectation, and find it is bounded by twice the Rademacher. This is in general. In particular if we apply this to $f = \ell \circ h$ and $\mathcal{F} = \mathcal{L}$ for $h \in \mathcal{H}$ our set of binary classifiers and ℓ the counting loss, this says that **the generalization gap is bounded by twice the Rademacher complexity**,

$$\mathbb{E}_{(x_1,y_1),\dots,(x_n,y_n)}\left[\sup_{\ell_h\in\mathcal{L}} \frac{1}{n}\sum_i \ell(h(x_i),y_i) - \mathbb{E}_{(x,y)}[\ell(h(x),y)]\right] \leq 2\mathcal{R}_n(\mathcal{L})$$

which is exactly our result.

Moreover, it holds that

$$\mathcal{R}_n(\mathcal{L}) = \frac{1}{2}\mathcal{R}_n(\mathcal{H})$$

So our result is not magical, it just says that the average deviation of a random variable from its expected value (over a sample) is bounded by twice the Rademacher. Think of functions with outputs 1 and -1: il risultato sopra ci dice che se per ogni sample $x_1, \dots, x_n$ noi prendiamo la funzione che massimizza la deviazione della media empirica dal valore atteso, e poi facciamo il valore atteso sui dati, la quantità che otteniamo è bounded dalla Rademacher. In altri termini, invece di guardare alla deviazione dal valore atteso posso guardare alla differenza tra le realizzazioni di una funzione su due campioni indipendenti, e cerco la funzione che mi massimizza questa differenza. La capacità di massimizzare questa differenza è bounded dalla Rademacher. Questa è la tecnica della simmetrizzazione.

Andando avanti, il Massart lemma mi dice poi che la Rademacher è maggiorata da $O(\sqrt{\log N(D)/n})$.